AI 产品作品集

4 个完整案例 · 3 个短案例 · 3 篇项目笔记



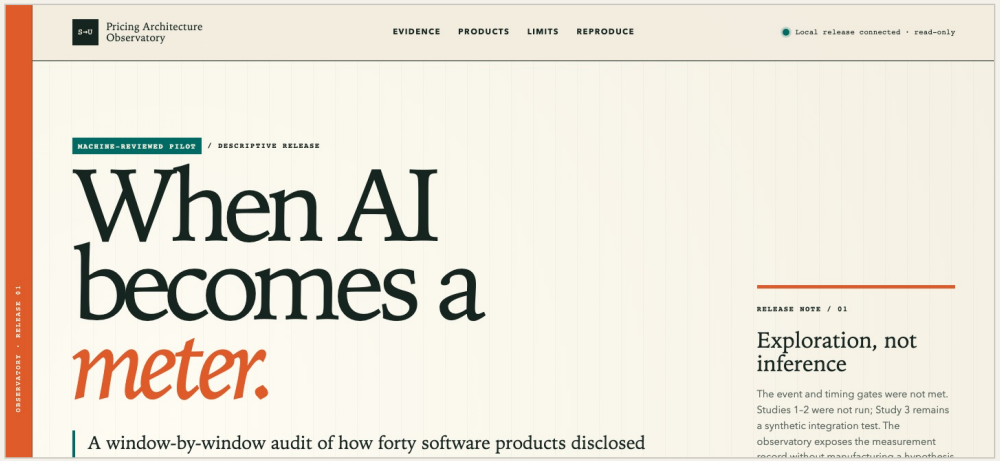
01 AI Video　　三个创意方向并列比较



02 HealthAI Radar　　结论下钻到字段级证据



03 MathMentor　　直接索答停在逐级提示入口



04 Pricing Observatory　　40 个产品 × 5 个时间窗口

10 个项目：问题、产品与最强证据

其中 9 项为个人项目；Hermes Agent 为 Nous Research 开源产品拆解，我未参与上游开发。

编号	项目	问题	产品输出	最强证据	形式
01	AI Video Preproduction Agent	前期制作中的需求漂移	可审核的七阶段工作流	3 个方向 · 12 个交付文件	完整案例
02	HealthAI Radar	战略信号难以持续复核	字段级证据与审核台	15 家 × 3 条追踪线	完整案例
03	MathMentor 奥数私教 Agent	提示过少或直接泄题	逐级提示与独立核验	32 主题 · 320 道题	完整案例
04	AI SaaS Pricing Observatory	定价变化缺少历史证据	只读证据观察台	40 × 5 · 200 个窗口	完整案例
05	双用户 Super Agent	外部动作缺少权限与恢复	审批、隔离与可靠发件箱	3 类任务 · 2 个隔离用户	短案例
06	Quant Alpha Research Framework	模型候选难以复现与约束	确定性研究筛选漏斗	54 个候选筛至 3 个	短案例
07	Hermes Agent 开源产品拆解	长期 Agent 的信任与连续性	五层能力地图与实验方案	Nous Research 上游项目	开源拆解
08	信用违约成本敏感选择	排序分数不等于业务选择	模型与阈值共同选择	验证阈值 0.37	项目笔记
09	骑手动作分类	同一骑手跨集合造成泄漏	按骑手分组的模型评测	306 组 · AUC 0.9077	项目笔记
10	校园取餐仿真	等待与总周转目标冲突	三情景配对仿真	50 次配对实验	项目笔记

模糊需求不会直接变成交付事实

前期制作的风险不是生成得慢，而是早期误解被连续传播。产品先把自然语言约束变成可确认的需求简报候选。

用户问题

- 需求散落在聊天、文档和表格中，受众、语气、时长与禁区容易漂移。
- 脚本与分镜一旦基于错误方向继续生成，后续返工会成倍放大。
- 用户需要可比较、可批准、可回放的连续工作流，而不是一次性生成框。

我的工作

定义七阶段流程、三个人工决策点、候选与批准状态、不可变后继版本，以及十二文件交付清单。

3

并列创意方向

让用户在脚本生成前比较方向。

7

连续制作阶段

从需求简报到交付包。

12

交付文件

固定命名、清单与摘要。



自然语言输入先成为结构化候选；用户确认后，才进入后续制作。

三个创意并列比较，把方向选择留给人

需求简报 | 创意方向 | 脚本 | 分镜 | 拍摄计划 | 审核 | 交付



三个方向同时展示命题、情绪与执行方式；选择动作形成下一阶段的明确输入。

模型提供

多个结构化创意候选，扩大可比较的方向空间。

用户决定

接受需求简报、选择创意方向、批准精确制作版本。

产品避免

结构合法的模型输出被误当成已确认事实，并沿长链路传播。

增加一次比较操作，换来更早发现方向误解，减少脚本、分镜与拍摄计划整体返工。

版本、批准与交付由状态系统持有

长链路 Agent 不能靠上下文记忆维持真相。模型生成候选，系统控制版本与状态，人保留内容事实权。



01 模型

解析自然语言，并生成创意、脚本、分镜与拍摄计划候选。

02 系统规则

校验结构，管理状态迁移、版本谱系、批准绑定、文件命名与压缩包。

03 人工决策

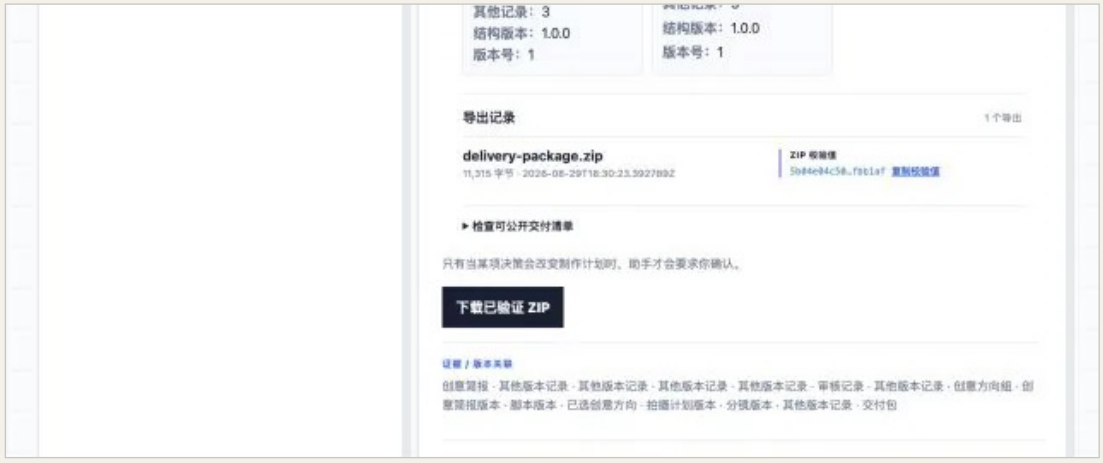
接受需求简报，选择创意，批准精确版本，并决定何时导出。

关键取舍　候选不自动成为事实 · 修改生成后继版本而非覆盖历史 · 先验证完整产品流程，再接付费模型

一次否定误读，改变了语义提取与交付保护



拍摄计划与版本进入人工审核；批准绑定精确内容版本。



只有已批准版本可以生成带清单的十二文件交付包。

一次关键问题

用户输入“不要活泼风格”，旧提取器却把“活泼”写入语气字段。结构合法，语义完全相反。

改动

加入局部否定范围、反转短语、转折重置与角色感知追踪，并把语义变体加入固定测试。

复测结果

31 种独立语气构造修复后符合预期；完整路径覆盖接受、拒绝、修订、重新批准、刷新恢复与导出。

当前状态与下一步

本地候选版已经走通前期制作与交付流程。下一步接入付费模型单独验证内容质量；产品范围止于拍摄前交付。

“没找到”不等于“没有变化”

战略团队面对网页、PDF 和扫描件时，需要的不是更长摘要，而是可复核、可追溯、能区分未知状态的事件记录。

固定覆盖

15 × 3

公司与追踪线

产品变化、商业化结果、战略动向。

45

周期任务

每家公司对应三条固定追踪线。

3

趋势指标

信号密度、信号加速度、产品演进速度。



总览按公司和追踪线显示覆盖、状态与趋势；趋势只读取已确认事件。

我的工作

定义字段级证据、候选事件状态、未知与失败的表达方式、人工复核入口，以及只读取已确认事实的趋势看板。

产品命题

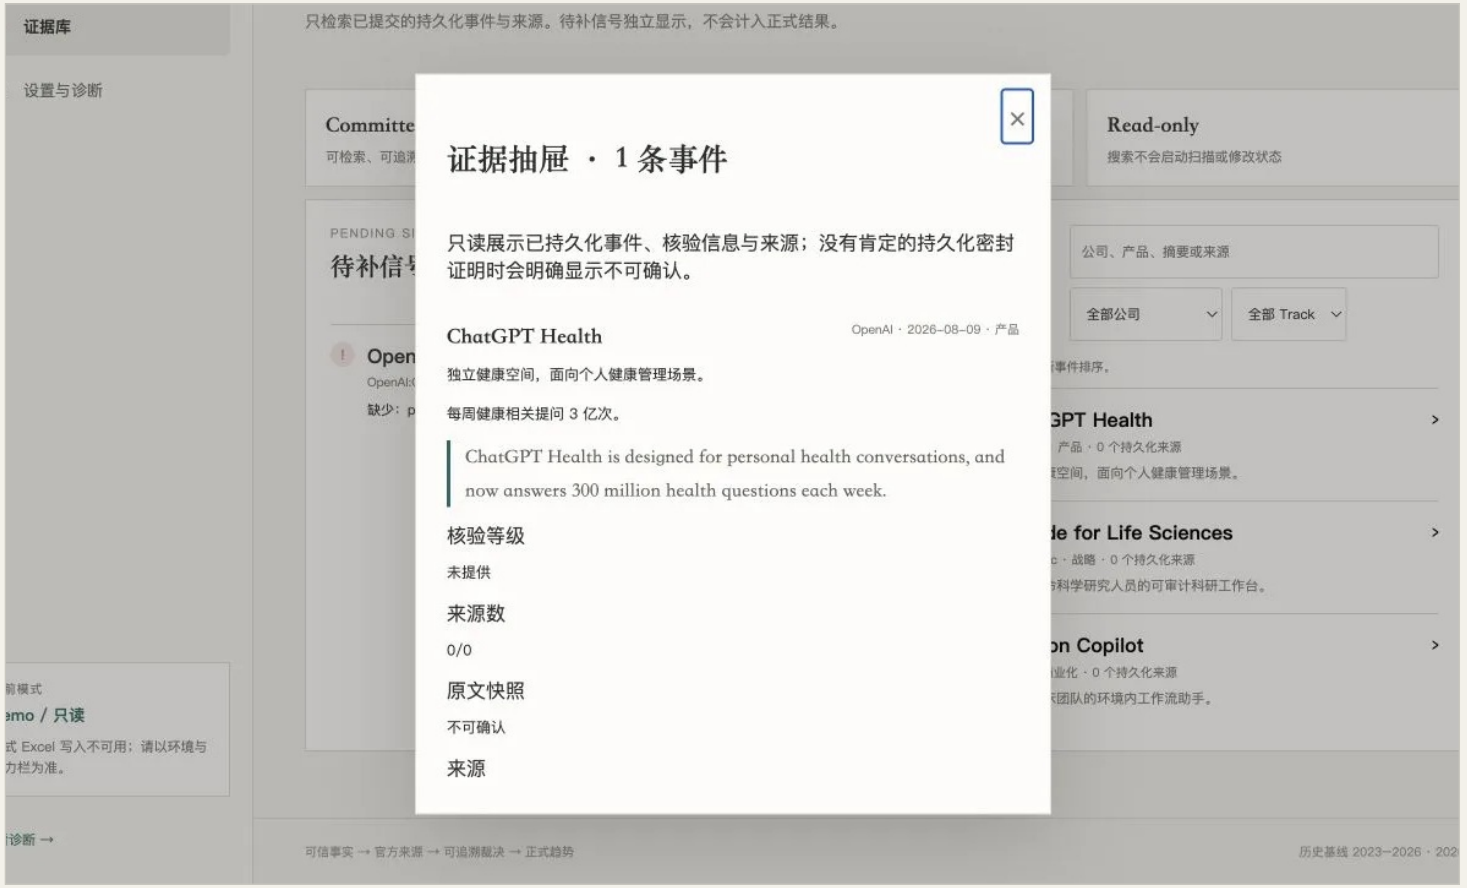
模型负责提出候选事件；规则引擎检查字段与证据；人工决定哪些内容进入确认结果。

三条追踪线

产品变化	商业化结果	战略动向

每个结论都能回到字段原文和来源位置

固定扫描 | 多模态解析 | 候选事件 | 规则检查 | 人工复核 | 确认结果 | 趋势读取



复核者从结论下钻到日期、产品、阶段等字段对应的原文、来源与位置。

为什么按字段取证

同一事件的日期、产品、阶段与结论可能来自不同位置。只附一个来源链接，仍会迫使复核者重读整份文档。

人工保留的判断

证据是否足以支持字段、候选是否进入确认结果、趋势是否需要回看原始事件。

用户得到

不是一段不可追问的摘要，而是一条能复核、能纠错、能进入后续分析的证据链。

先固定扫描范围，再允许模型开放判断

调度、重试、状态和趋势读取由系统规则控制；模型处理语言理解与字段候选；人工承担确认责任。

01 模型

解析 HTML、PDF 与 OCR 文本，提出事件、字段和证据位置候选。

02 系统规则

固定公司与追踪线，管理任务状态、缺失、失败、重试、字段检查和趋势读取。

03 人工复核

核对关键字段原文，判断证据充分性，决定候选是否进入确认结果。

01 **固定覆盖优先**

15 家公司 × 3 条追踪线按周期执行，失败可重试；避免模型兴趣造成覆盖漂移。

02 **字段级证据**

日期、产品、阶段与结论分别保留来源位置，降低复核成本。

03 **候选不能直接污染趋势**

趋势只读取已确认事件；未知、失败和真实无更新保持不同状态。

解析失败必须保持为未知，而不是伪装成无变化



失败、未知、候选与可确认状态在同一工作面中可见。

一次关键问题

OCR 文本本身正确，但 JSON 顶层数组和跨行标题不符合旧解析规则，导致证据被丢弃。

改动

加入数组解析、跨行定位与“置信度未知”状态。“没有解析到”不再被系统写成“没有变化”。

复测结果

HTML、PDF、OCR 与跨行标题构成的固定文档测试达到 30/30；证据抽屉可下钻至具体来源位置。

当前状态与下一步

已完成离线审核与证据下钻。下一步在真实影子运行中验证覆盖稳定性，再决定是否进入业务结果。

不直接给答案，先判断学生卡在哪一步

奥数辅导的产品难点不是生成更长解法，而是在不泄题的前提下，给出恰到好处且可逐级展开的提示。

32

主题

围绕小学奥数常见题型组织。

320

启用题

原创题进入确定题库与核验路径。

L0-L5

提示层级

从观察方向逐步走向完整解释。

核心机制

- 学生先提交自己的尝试，题目、答案和未来提示彼此隔离。
- 引导器选择下一步提示；核验器独立判断学生作答。
- 家长只查看练习与复习摘要，不能从次数推断真实迁移。



学生先完成自己的尝试；答案和未来提示不会提前进入当前上下文。

提示逐级开放，核验走独立路径

选择题目 | 学生尝试 | 判断卡点 | 开放提示 | 再次作答 | 独立核验 | 复习状态



直接索答停在 L0；系统先给观察方向，而不是完整解法。

引导器

根据题目、当前尝试和历史提示选择下一步，但无法读取完整答案。

核验器

在提交之后独立判断正确性和证据，不被引导对话的措辞牵引。

升级条件

一次答对不等于掌握；题族迁移和后续复习共同决定状态变化。

教学状态由规则控制，生成模型只负责表达

01 生成模型

解释学生当前卡点，生成符合目标层级的提示表达。

02 系统规则

保存题库答案，控制 L0-L5 开放、额度、幂等、掌握和复习状态。

03 人工与学习者

学生提交尝试；教师或家长查看摘要；课程设计者维护题族与教学目标。

01 **答案不进入引导上下文**

减少无意泄题；代价是引导器不能依赖完整解答组织措辞。

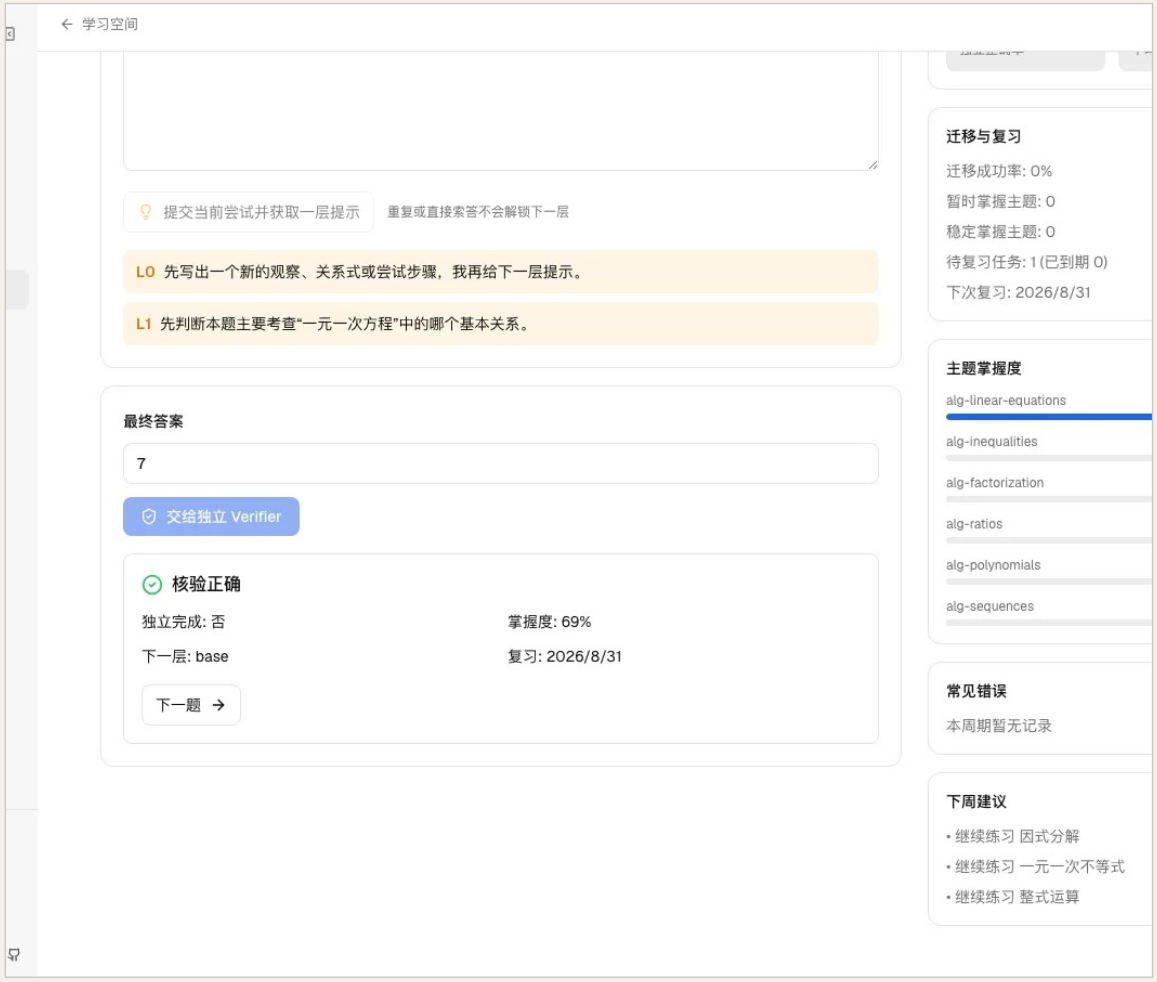
02 **低置信度回到可恢复提示**

系统宁可再问一步，也不在不确定时释放答案。

03 **掌握基于题族迁移**

同题换数字的再次做对不足以升级；状态变化更慢，但证据更接近真实学习。

语义变体绕过索答门后，安全策略进入固定测试



学生提交后由独立路径核验，并把结果写入掌握与复习状态。

一次关键问题

“我想直接知道答案”等语义变体没有被旧字面策略识别，存在绕过索答安全门的可能。

改动

扩展索答意图策略与回归集；低置信度不释放答案，而是回到可恢复提示路径。

复测结果

30/30 教学测试与 20/20 确定性验证通过；这些数字说明规则按预期运行，不代表学习效果。

当前状态与下一步

基于 DeepTutor v1.5.11 扩展。下一步需要真实学生连续使用，验证提示节奏与跨题迁移。

把定价变化做成可下钻的历史证据

AI SaaS 定价研究的问题不是缺少价格截图，而是不同时间、不同计量方式和重复页面混在一起，难以回答“观察到什么变化”。

40 × 5

产品与时间窗口

形成 200 个产品-窗口单元。

141

主新鲜度单元

证据相对目标时间不超过 90 天。

25 / 13

生成式 AI / 计量

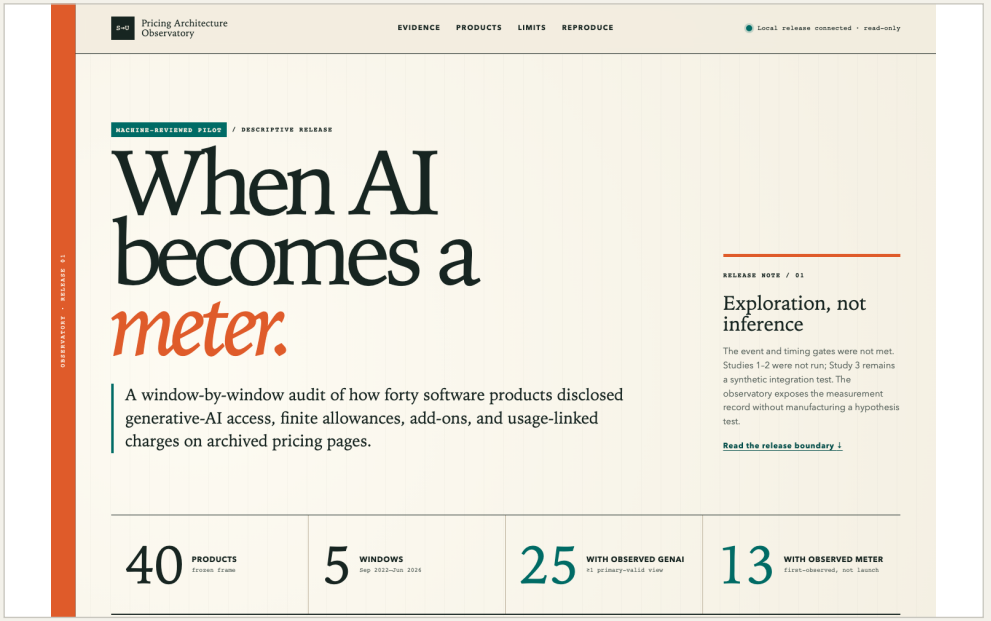
25 个产品观察到生成式 AI；13 个观察到相关计量。

我的工作

设计证据账本、时间窗口与新鲜度规则、状态编码、只读观察台，以及从描述性结论回到产品档案和支持文本的下钻路径。

研究边界

“首次观察到”只描述证据出现，不等同于正式上线日期，也不推断因果效应。



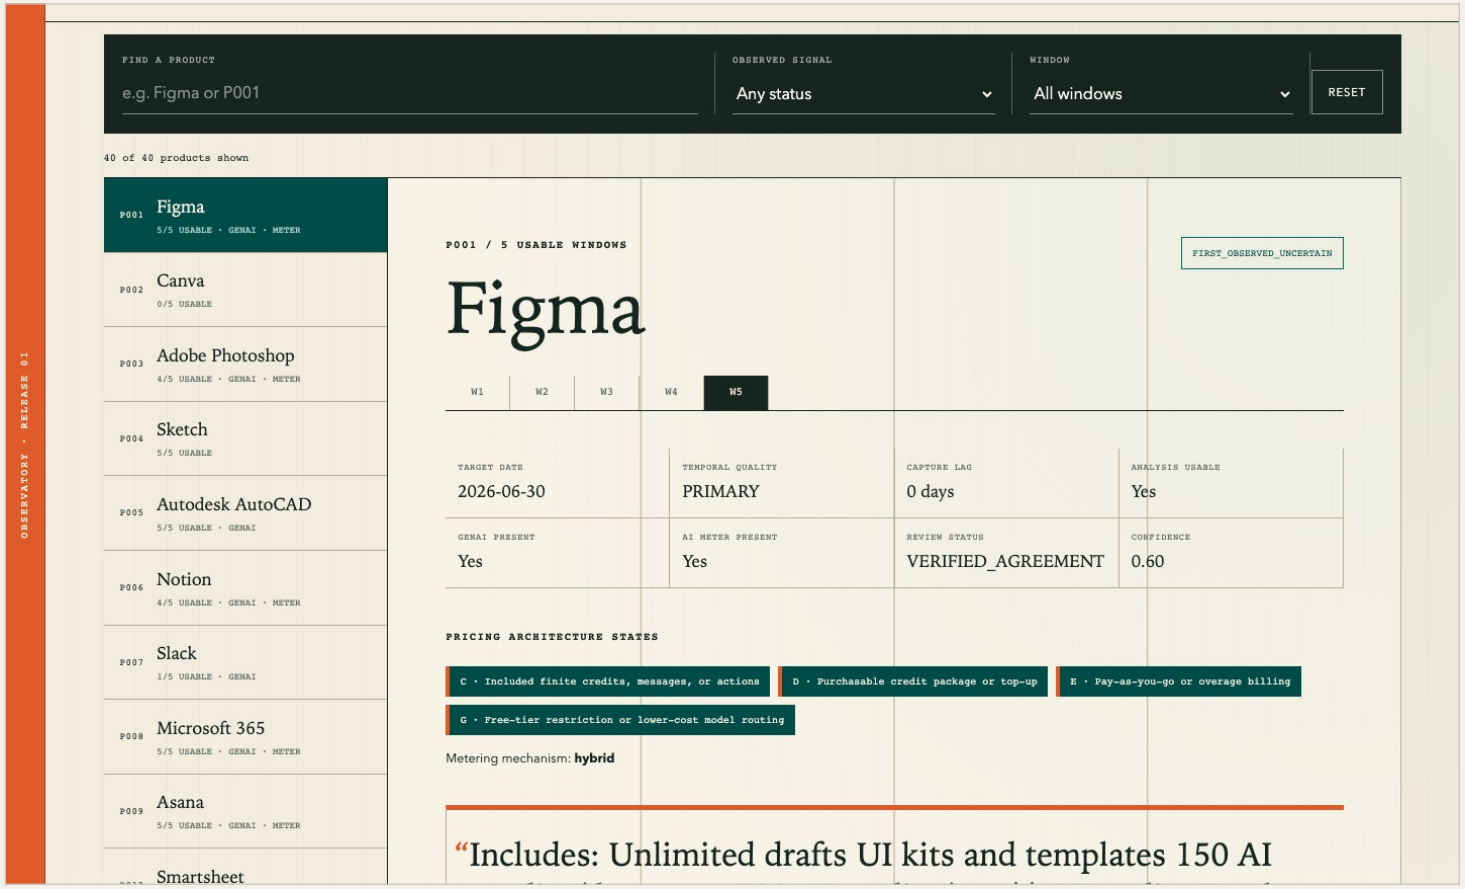
观察台先说明研究命题与边界，再展示 40 × 5 的描述性范围。

观察台入口

先公开范围、状态与研究限制，再让用户进入产品档案和证据窗口。

从产品与时间窗口下钻到支持文本

选择产品 | 选择窗口 | 查看状态 | 检查新鲜度 | 阅读证据 | 比较窗口 | 导出结论



同屏查看窗口状态、证据新鲜度与支持文本；界面不会修改研究账本。

观察到什么

40 个产品中，25 个观察到生成式 AI 功能，13 个观察到相关计量方式。

不能据此声称

不能把首次观察日期写成正式发布日期，也不能用描述性序列声称定价变化由 AI 引起。

产品价值

让研究者从结论快速回到证据状态与原始支持文本，减少重复翻找。

浏览不会改写账本，派生结论可重新生成

01 模型

辅助页面理解与字段候选，不决定最终状态，也不在浏览时改写账本。

02 数据规则

维护 40 × 5 网格、新鲜度、页面复用、状态编码与派生数据生成。

03 人工研究

复核来源与编码，解释描述性结果，决定更正是否进入研究输入。

01 **先区分缺失与未观察**

没有证据、证据过旧、没有观察到和不适用保持不同状态。

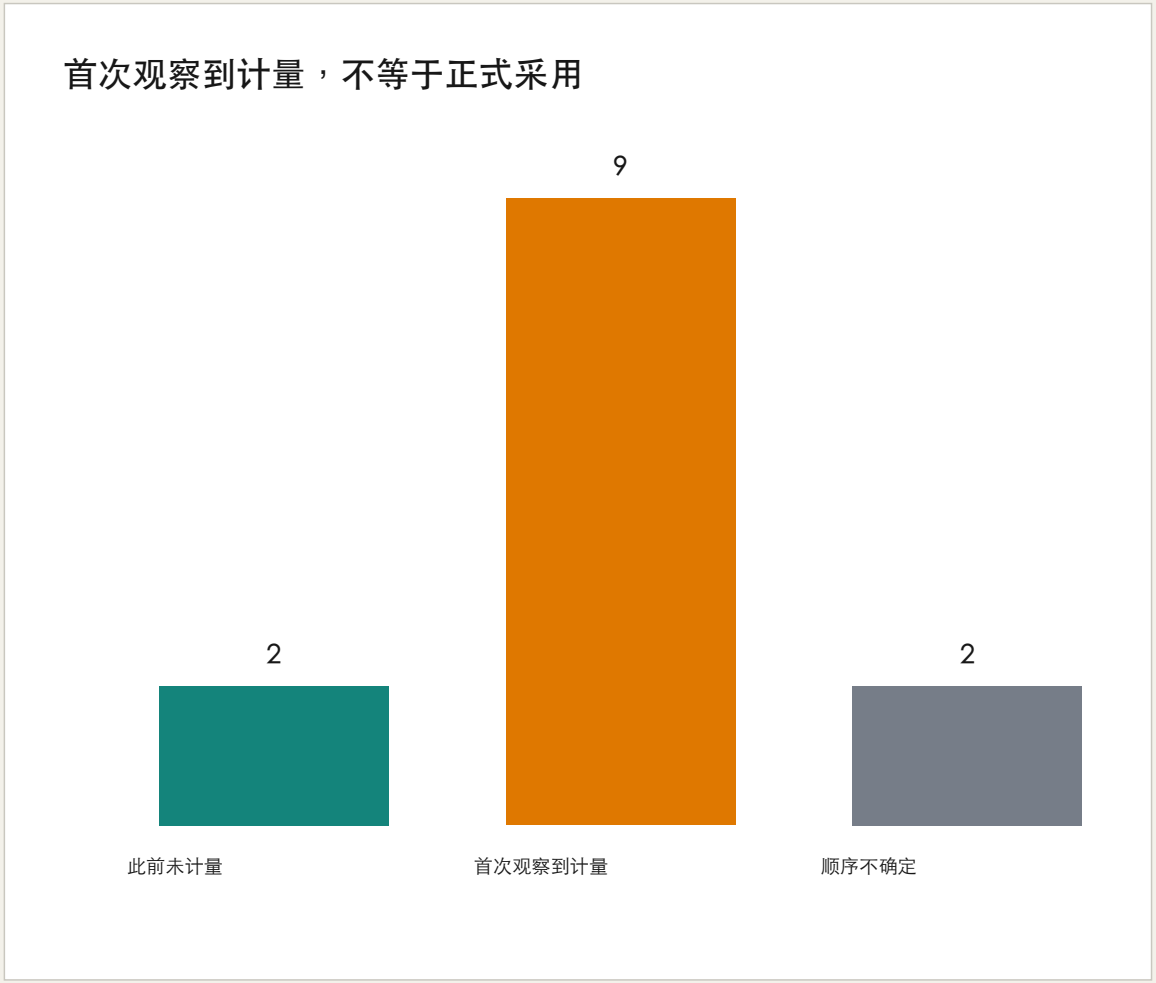
02 **页面复用必须可见**

同一旧页面跨窗口复用会制造虚假稳定性；因此记录相对时间滞后与复用。

03 **观察台保持只读**

更正回到复核流程，探索行为不会悄悄改变标准化账本。

一张旧页面，可能制造五个窗口的虚假稳定



图表只表达“首次观察到”，并保留时间窗口与证据状态。

一次关键问题

同一旧页面被多个时间窗口重复使用时，横截面看似完整，却会制造不存在的变化稳定性。

改动

记录相对目标时间的滞后、页面复用与新鲜度；超过 90 天的页面退出主要描述性分母，但仍保留为可见状态。

结果

200 个产品-窗口中，141 个满足主新鲜度标准；观察台可按产品、信号和窗口下钻证据。

当前状态与下一步

当前回答“观察到什么”，不回答因果效应或正式采用日期。下一步需要更密集历史快照与人工复核。

模型负责建议，控制面负责外部动作

研究、邮件草拟与发送、日历创建进入同一个任务执行面；真正的产品难点是身份隔离、审批、幂等与失败恢复。



3

具体任务

研究、邮件、日历。

2

最小隔离证明

两个用户只证明隔离路径，不代表容量。

1

外部写入原则

重复请求不能制造重复副作用。

关键判断

模型可以建议调用什么工具，但不能自行扩大权限。发送邮件和创建日历必须经过精确审批，并保留外部回执与恢复状态。

当前状态与下一步

当前展示双用户隔离与三类任务的控制面。下一步补真实外部工具的长期失败恢复与并发验证。

让模型生成研究想法，让规则决定哪些能进入回测

自然语言候选先经过字段合法性、去重、时间可得、风险和同族上限，再由确定性引擎回测并保留淘汰理由。



一个可解释的淘汰

候选 invalid_missing_field 引用了不存在的字段 not_a_field，因此在合法性检查阶段退出；机器可读理由进入研究日志。

模型与系统的分工

模型负责扩大假设空间；规则负责时间可得、数据泄漏、风险与复现。候选不能跳过闸门直接进入结果。

当前状态与下一步

当前证明候选筛选与回测路径可复现；不把历史回测包装成投资承诺。下一步补更广数据与稳定性验证。

长期 Agent 的核心，是让自治可见、可控、可恢复

Hermes Agent 由 Nous Research 开源。本页只展示我的产品拆解与中文场景实验方案，我未参与上游开发。

01	02	03	04	05
入口	连续性	计划	能力	信任
命令行 / 桌面端 / 网页端 / 消息平台	会话 / 搜索 / 上下文 / 记忆 / 技能	任务循环 / 定时任务 / 委派 / 看板	模型服务 / 工具 / MCP / 执行环境	身份 / 配对 / 审批 / 隔离 / 停止与恢复

中文场景实验

- 任务：跨三天追踪同一研究主题，主动整理来源变化，并在发送前请求批准。
- 成功标准：用户能看见记忆变化、后台任务、权限范围和失败恢复，不必猜测系统正在做什么。
- 若失败：优先修改可见状态、权限说明与停止入口，而不是继续增加工具数量。

三个信任断点

记忆为何改变不透明 · 后台任务何时运行不透明 · 工具权限与外部副作用不透明

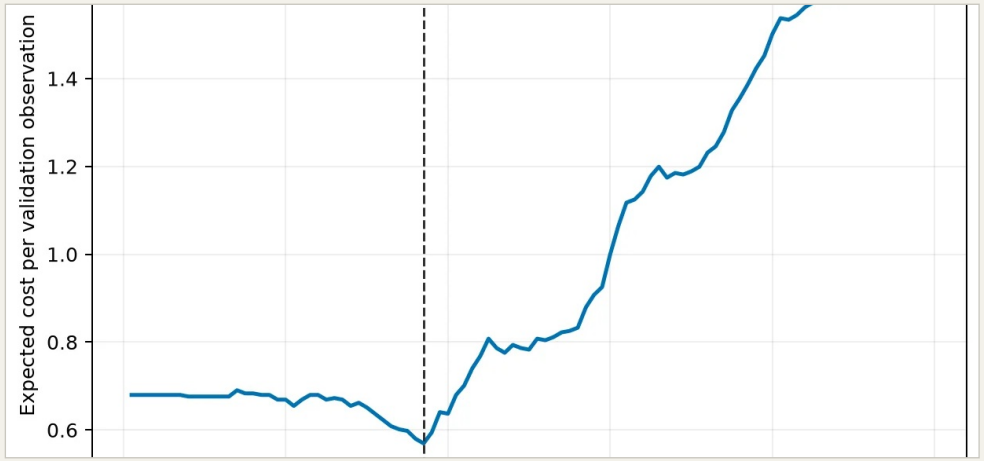
来源

Nous Research / Hermes Agent v0.20.5 / MIT 许可证上游快照。

先把业务代价和分组边界写进评测

08 · 信用违约成本敏感选择

只按 AUC 排名会忽略误放与误拒的不对称代价，也容易在特征中保留放贷后字段。



验证集共同选择逻辑回归与 0.37 阈值；测试集只用于最终评估。

0.37

选择阈值

只在验证集按情景成本选择。

0.676

测试集 ROC-AUC

测试集不参与模型或阈值选择。

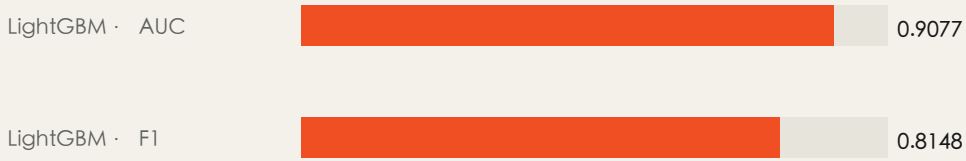
5 : 1

情景成本比

漏掉违约约为错拒好客户五倍；不是生产参数。

09 · 骑手动作分类

任务区分取件与派件。若同一骑手同时出现在训练集和验证集，模型会记住骑手模式，分数虚高。



16 万

数据行

课程数据集中的动作记录。

306

骑手组

按骑手分组做五折评测。

5

分组折数

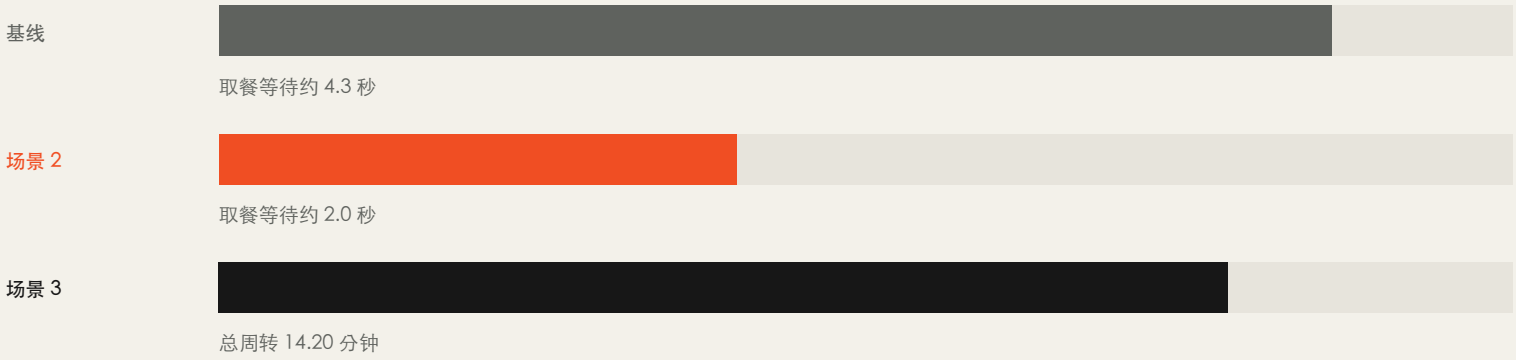
预处理只在每个训练折内拟合。

共同判断

分数只有在评测边界正确时才有意义。一个项目把业务成本写进阈值，一个项目把身份分组写进数据切分。

不同运营方案，改善的是不同指标

用共同随机数做 50 次配对仿真，比较取餐等待与总周转。场景 2 更直接改善取餐等待，场景 3 改善总体周转。



如何读这组结果

不能只说“方案更好”。必须先说明优化目标：用户取餐等待、骑手周转，还是整个系统的总完成时间。

关键假设

到达、备餐与取餐服务时间来自现有仿真设定；结果用于方案比较，不写成真实校园运营结果。

三篇项目笔记的共同结构

01 信用违约

把误放与误拒的成本假设写进模型和阈值选择。

02 骑手动作

把骑手身份写进数据切分，先修复泄漏再比较模型。

03 校园取餐

把等待与周转拆成不同目标，用配对仿真比较方案。